

Octave part en vendanges, le pipeline prend le relais

Mission : concevez, orchestrez et testez avec Kestra la chaîne de traitement des ventes du Comptoir des Coteaux.



Comment allez-vous procéder ?

Cette mission suit un scénario de projet professionnel, raconté par les mails que vous recevez au fil de la semaine. Elle se déroule en deux temps : le cadrage du besoin, puis la réalisation guidée du pipeline jusqu'à la soutenance.

Avant de démarrer :

- lisez toute la mission et téléchargez les données : [exports_comptoir.zip](#) ;
- notez ce que vous avez compris, et ce qui reste flou ;
- parcourez les étapes pour vous repérer ;
- préparez vos questions pour votre premier point avec Solène ;
- ouvrez votre projet dans [OpenProject](#) : c'est là que vous planifierez et rendrez compte de votre semaine.

Objectif Cadrage (C1, C3) puis projet intégrateur	Orchestration Kestra	Traitement SQL (DuckDB) et Python (pandas)	Suivi de projet OpenProject : backlog et Kanban	Rendu Un lien GitHub, puis soutenance de 3 min
---	--------------------------------	--	---	--

Votre premier lundi au Comptoir

Vous venez d'être recruté-e comme Data Engineer au **Comptoir des Coteaux**, un négociant en vins qui fournit des restaurateurs et des entreprises d'un côté, des particuliers via sa boutique en ligne de l'autre. L'équipe est petite, on s'y tutoie, et le vendredi à 17h on goûte une bouteille du catalogue.

Solène, responsable du pôle data et votre manager sur cette mission, vous fait faire le tour des bureaux. Vous rencontrez celles et ceux avec qui vous allez travailler :



Devant la machine à café, Solène vous explique pourquoi vous arrivez au bon moment :

« Nos produits vivent dans deux systèmes qui ne se parlent pas : l'ERP pour les prix et les stocks, le CMS de la boutique pour les ventes. Chaque mois, Octave recolle tout ça à la main dans un notebook, calcule le chiffre d'affaires et sort la liste des vins premium. Tout le monde adore ses chiffres. Sauf que vendredi soir, Octave part trois semaines faire les vendanges chez un de nos vignerons partenaires, et que le rapport du 15 ne va pas se faire tout seul. Enfin si, justement : c'est ce que j'aimerais que tu construises. »

Solène, responsable du pôle data

Octave ajoute, en riant, que le mois dernier un doublon s'est glissé dans sa liste : un restaurateur a reçu deux fois la même offre de Capucine et a répondu « Message reçu, j'en prends deux caisses ». L'histoire a fait le tour des bureaux, mais personne ne compte sur la chance une deuxième fois.

De retour à votre poste, le premier mail vous attend.



Solène

À : moi. Cc : Octave

Lundi 21 sept.

09:12

Les exports et la méthode d'Octave

Re-bonjour,

Comme promis, tu trouveras dans le zip les deux exports : celui de l'ERP (`Fichier_erp.xlsx`) et celui du CMS de la boutique en ligne (`Fichier_web.xlsx`). Les deux systèmes n'utilisent pas les mêmes identifiants : `product_id` côté ERP, `sku` côté web. Il faut donc passer par la table de correspondance (`fichier_liaison.xlsx` , colonnes `product_id` et `id_web`) pour les réconcilier.

La méthode d'Octave, telle qu'il me l'a décrite :

- suppression des valeurs manquantes et dédoublonnage des trois fichiers, pour obtenir des clés primaires uniques avant toute jointure ;
- jointure des deux fichiers propres via `fichier_liaison.xlsx` ;
- calcul du chiffre d'affaires par bouteille, puis du chiffre d'affaires total, sur les données fusionnées ;
- identification des vins premium par z-score sur le prix : $z = (\text{prix} - \text{moyenne}) / \text{écart-type}$. Un vin est premium si $z > 2$, ordinaire sinon.

Ta mission : **industrialiser ce processus**, pour que Capucine et Théo reçoivent leurs fichiers sans que personne n'ait à y penser.

Ce que j'attends, concrètement :

- **l'architecture de l'automatisation** : l'enchaînement des tâches d'Octave (nettoyages, jointures, agrégations, extractions) avec, après chaque tâche, une **tâche de test** qui vérifie que le résultat est juste. Après l'épisode des deux caisses, on y tient tous ;
- **son implémentation**, tests compris, sur l'orchestrateur retenu par la DSI (Nadir t'écrit à ce sujet) ;
- le **rapport Excel** avec le chiffre d'affaires par produit et le chiffre d'affaires total ;
- les **deux extractions** : vins premium, vins ordinaires ;
- une **exécution planifiée** le 15 de chaque mois à 9h ;

- une réponse à la question « que se passe-t-il si quelque chose casse ? », par exemple si un service tiers comme DuckDB est indisponible.

Octave est là jusqu'à vendredi soir pour tes questions sur l'analyse. Profites-en, après il sera dans les rangs de vigne, sans réseau.

Solène

P.J. : **exports_comptoir.zip** contient **Fichier_erp.xlsx** **Fichier_web.xlsx**
fichier_liaison.xlsx

Dans la matinée, deux autres messages arrivent.



Nadir, DSI

À : moi. Cc : Solène

Lundi 21 sept.

10:40

Orchestrateur : ce sera Kestra

Bonjour et bienvenue parmi nous,

Côté DSI, nous avons standardisé l'orchestration sur **Kestra** : déclaratif, lisible par des non-développeurs, simple à prendre en main. Merci de t'y tenir.

- Installe-le en local avec Docker, en suivant le kit d'installation officiel.
- Garde des captures d'écran de l'installation et d'une exécution réussie, je te les demanderai au COPIL.
- Traitements en SQL avec DuckDB, et en Python avec pandas pour la partie statistique.
- Tout ton travail vit dans un **dépôt GitHub** : le YAML, les scripts, le logigramme, le support. Des commits réguliers, un README qui explique comment lancer le pipeline. Envoie le lien à Solène en fin de semaine, c'est lui qui fait foi comme rendu.

Un principe auquel je tiens : Kestra orchestre, il ne traite pas. La logique métier vit dans tes scripts, pas dans le YAML. Pense aussi au jour où une tâche tombera en erreur, et à celui où l'on te demandera de brancher une quatrième source.

Au COPIL, je te demanderai pourquoi Kestra et pourquoi DuckDB. « Parce que Nadir l'a dit » ne comptera pas, même si ça me ferait plaisir. Ma porte est ouverte si tu veux en discuter avant.

Nadir



Capucine
À : moi. Cc : Théo

Lundi 21 sept.
11:25

Ce dont on a besoin, Théo et moi

Bonjour,

Octave t'a sûrement raconté l'histoire des deux caisses. Commercialement, je ne me plains pas, mais j'aimerais autant que mes clients reçoivent chaque offre une seule fois.

Pour mes campagnes auprès des professionnels, il me faut la **liste des vins premium**, en `.csv`. Théo, lui, travaille les particuliers avec la **liste des vins ordinaires**, en `.csv` également. Et nous ouvrons ensemble notre réunion produits avec le **rapport de chiffre d'affaires par produit** et son total, au format Excel.

Si les trois fichiers nous attendent le 15 du mois à 9h, nos campagnes partent dans la journée. Et si tu peux nous expliquer au COPIL comment ça marche, avec des mots simples, Théo promet d'apporter les gougères.

Capucine

Livrables attendus

#	Livrable	Format
1	Logigramme du pipeline : tâches, tests, liaisons	<code>.drawio</code> et export image
2	Workflow Kestra complet, scripts intégrés	<code>.yaml</code>
3	Rapport chiffre d'affaires par produit et CA total	<code>.xlsx</code>
4	Liste des vins premium	<code>.csv</code>
5	Liste des vins ordinaires	<code>.csv</code>
6	Planification automatique le 15 du mois à 9h	Trigger cron Kestra
7	Support de soutenance : contexte, démarche, justifications	<code>.pptx</code>

#	Livrable	Format
8	Dépôt GitHub regroupant tous les livrables ci-dessus, avec un README	Lien du dépôt

Votre rendu : un seul lien GitHub

Vous ne rendez pas de fichiers par mail. Vous transmettez **le lien de votre dépôt GitHub** à votre formateur·rice, au plus tard le vendredi 25 au soir pour le pipeline, puis avant la soutenance pour le support. Le dépôt est public, ou privé avec votre formateur·rice en collaborateur.


Emplacement	Contenu
README.md	Contexte en 5 lignes, prérequis, commandes pour lancer Kestra et exécuter le flow, résultats obtenus face aux valeurs d'Octave, lien vers votre projet OpenProject
docs/	Note de cadrage, logigramme (drawio et image), captures d'écran de Kestra
flows/	Le workflow Kestra .yaml
scripts/	Scripts SQL DuckDB et script Python, si vous les versionnez aussi hors du YAML
data/	Les 3 exports sources
outputs/	Rapport CA .xlsx , vins premium .csv , vins ordinaires .csv
soutenance/	Support .pptx

- Commitez au fil de l'eau, au moins une fois par étape, avec des messages qui disent ce qui a changé. Un unique commit « rendu final » le vendredi soir ne montre rien de votre démarche.
- Aucun mot de passe ni jeton dans le dépôt. Ajoutez un .gitignore (volumes Docker, environnements Python, fichiers temporaires).
- Testez votre README sur une machine propre, ou faites-le relire : quelqu'un qui clone le dépôt doit pouvoir relancer le pipeline.

Documentation officielle : [premiers pas avec GitHub](#) et [gérer un dépôt](#).

Pilotez votre semaine avec OpenProject

Au Comptoir, aucun projet ne se suit par mail : tout passe par [OpenProject](#), un outil libre de gestion de projet. Solène attend de vous un **backlog** saisi dès lundi et un **tableau Kanban** tenu à jour chaque jour. C'est aussi ce qui prouvera, en fin de semaine, que vous savez planifier (C5) et rendre compte (C7).



Comment vous en servir :

- **Lundi**, créez un lot de travail par tâche du tableau ci-dessous, avec une date d'échéance, l'étape concernée et le livrable visé.
- **Chaque matin**, déplacez vos cartes. Une seule carte « En cours » à la fois, c'est un bon réflexe.
- **Chaque soir**, notez en commentaire de la carte ce qui a bloqué et ce que vous avez décidé. Votre journal de bord est là, inutile d'en tenir un second.
- **En cas de retard**, décalez la date et expliquez pourquoi, plutôt que de laisser la carte en rouge.

Lot de travail	Étape	Échéance
Explorer les 3 fichiers et lister les contraintes	0	Lun. 21
Rédiger la note de cadrage	0	Lun. 21
Créer le dépôt GitHub et son README	0	Lun. 21
Dessiner le logigramme, tests compris	1	Mar. 22
Installer Kestra avec Docker, captures d'écran	2	Mer. 23
Scripts SQL : valeurs manquantes, dédoublonnage	2	Mer. 23
Scripts SQL : fusion, chiffre d'affaires	2	Jeu. 24
Script Python z-score, branches premium et ordinaires	2	Jeu. 24

Lot de travail	Étape	Échéance
Exports .xlsx et .csv, trigger cron	2	Jeu. 24
Les 5 familles de tests et contrôle des valeurs d'Octave	3	Ven. 25
Gestion des erreurs (service indisponible)	3	Ven. 25
README finalisé, envoi du lien GitHub à Solène	3	Ven. 25
Support de soutenance et répétition	4	Semaine suivante

Site officiel : openproject.org/fr. Documentation : [les tableaux agiles \(Kanban\)](#) et [le backlog et les sprints](#).

Les étapes



Cadrez le besoin

Lundi 21. Compétences C1, C3, C5



En début d'après-midi, Solène revient vers vous :



Solène

À : moi

Lundi 21 sept.

14:05

Avant de coder : ta note de cadrage

Prends le temps de bien comprendre avant de te lancer, personne ne t'attend au tournant. Avant la moindre ligne de code, envoie-moi une note de dix à quinze lignes : le besoin métier tel que tu l'as compris, le périmètre technique que tu retiens, les contraintes que tu vois dans les sources, et tes questions en attente.

Écris aussi ce qui reste flou. C'est fait pour ça.

Et ouvre ton projet dans **OpenProject** : un backlog découpé par jour, un tableau Kanban tenu à jour. Je suivrai ton avancement là-dessus, ça

m'évitera de venir te déranger, et ça te fera un beau support pour raconter ta semaine.

Solène

À faire

- Relire tous les mails et ouvrir les trois fichiers : colonnes, types, clés probables, valeurs manquantes, doublons.
- Identifier les contraintes propres aux sources : formats, qualité, volumétrie.
- Lister les livrables exacts attendus par Capucine et Théo.
- Préparer vos questions pour le point avec Solène.
- Créer votre dépôt GitHub avec un premier README, et y déposer la note de cadrage.
- Créer votre projet OpenProject, saisir le backlog et le découper par jour (voir la section « Pilotez votre semaine »).

Résultat attendu

- Une note de cadrage de 10 à 15 lignes : besoin métier, périmètre technique, contraintes identifiées, questions en attente.
- Un projet OpenProject avec le backlog de la semaine, chaque lot daté et rattaché à une étape.

1

Concevez l'architecture d'automatisation (Data Lineage)

Mardi 22. Compétences C3, C5



Prérequis

- Avoir identifié l'enchaînement des tâches demandées.
- Avoir compris les techniques de schématisation par diagramme (voir [Five Features That Help You to Draw Better Diagrams](#)).

Résultat attendu

- Un diagramme de flux présentant :

- les tâches à effectuer à partir des 3 fichiers (`Fichier_erp.xlsx` , `fichier_liaison.xlsx` , `Fichier_web.xlsx`) pour aboutir au rapport Excel (CA par produit, CA total) et aux extractions des vins premium et ordinaires ;
- après chaque tâche, la tâche de test associée ;
- les liaisons entre ces tâches.

Recommandations

- **Documentez systématiquement votre travail.** Un journal de bord aide à suivre les étapes franchies, les difficultés rencontrées et les solutions trouvées.
- Ne sous-estimez pas cette étape : elle vous fait penser toute la chaîne avant de la coder.

Outils

- [Draw.io \(app.diagrams.net\)](https://app.diagrams.net)

Point de vigilance

- Schématisez les tests. Un test absent du logigramme finit presque toujours absent du code. C'est comme ça qu'on se retrouve à vendre deux caisses par accident.

Ressources

- Mieux dessiner ses diagrammes : [Five Features That Help You to Draw Better Diagrams](#)
- Rappel sur le logigramme : [Qu'est-ce qu'un logigramme, Lucid](#)
- Exemple de diagramme de flux : [Pipelines, documentation Elyra](#)

2

Orchestrez les tâches nominales avec Kestra

Mercredi 23 et jeudi 24. Compétences C8, C9, C10



Prérequis

- Avoir parcouru la documentation de [Kestra](#) : [les composants d'un workflow](#) (flows, tasks, triggers, exécutions).

- Avoir installé Kestra avec Docker en suivant le [guide d'installation](#), captures d'écran à l'appui comme le demande Nadir.

Résultats attendus

- Le fichier `.yaml` Kestra, cohérent avec votre logigramme, qui intègre les scripts :
 - SQL DuckDB, suppression des valeurs manquantes ;
 - SQL DuckDB, dédoublonnage ;
 - SQL DuckDB, fusion des deux systèmes (ERP et web, via liaison) ;
 - SQL DuckDB, chiffre d'affaires par produit et chiffre d'affaires global ;
 - Python, identification des vins premium et ordinaires : $z = (\text{prix du vin} - \text{moyenne des prix}) / \text{écart-type des prix}$, premium si $z > 2$.
- Après exécution : le rapport CA par produit en `.xlsx`, la liste des vins premium en `.csv`, la liste des vins ordinaires en `.csv`.
- Une planification du workflow complet tous les 15 du mois à 9h, avec un trigger et une expression cron (à vérifier sur [Crontab.guru](#)).

Recommandations

- **Documentez systématiquement votre travail.**
- Utilisez le mécanisme de branches de Kestra pour séparer l'extraction des vins premium de celle des vins ordinaires.

Outils

- Kestra
- Python et ses dépendances (pandas...)
- SQL et [DuckDB](#)

Points de vigilance

- Kestra est un outil d'orchestration, pas un outil de traitement de données.
- Anticipez deux situations : l'arrivée d'une nouvelle source de données, et une tâche du workflow en erreur.

Ressources

- Kestra, déclarer un flow et ses tâches : [Flow](#)
- Kestra, planifier avec une expression cron : [Schedule Trigger](#)
- Kestra, réagir à une tâche en échec : [Retries](#)
- DuckDB : [documentation officielle](#)
- Vérifier son expression cron : [Crontab.guru](#)

3

Implémentez les tâches de tests avec Kestra

Vendredi 25. Compétence C9



Vendredi matin, valise déjà dans le coffre, Octave vous laisse ses chiffres :



Octave

À : moi

Vendredi 25 sept.

08:35

Mes résultats, pour caler tes tests

Salut,

Avant de troquer mon clavier contre un sécateur, voici mes résultats intermédiaires sur les exports que Solène t'a transmis. Si ton pipeline retombe dessus, je pars l'esprit léger.

Étape	Valeur attendue
ERP après dédoublonnage	825 lignes
Liaison après dédoublonnage	825 lignes
Web après nettoyage	1 428 lignes
Web après dédoublonnage	714 lignes
Fichier fusionné	714 lignes
Chiffre d'affaires total	70 568,60 €
Vins premium détectés (z > 2)	30

Un conseil de quelqu'un qui a déjà vendu deux caisses sans le vouloir : si tes chiffres s'écartent des miens, cherche en amont, dans le dédoublonnage ou la jointure, avant de soupçonner le z-score.

Moi je vérifiais à l'œil. Le 15 à 9h, je serai dans les vignes et personne ne regardera. D'où les tests. Je te rapporte une bouteille.

Octave

Prérequis

- Avoir un pipeline nominal fonctionnel (étape 2).

Résultats attendus

- Des tâches de tests, en SQL ou en Python, placées après les tâches nominales :
 - tests d'absence de doublons ;
 - tests d'absence de valeurs manquantes ;
 - tests de cohérence des jointures ;
 - tests de cohérence du chiffre d'affaires ;
 - test du z-score sur le prix des vins.
- Le fichier `.yaml` Kestra enrichi de ces tâches de tests.

Recommandations

- **Documentez systématiquement votre travail.**
- Ajoutez les tests aux tâches de l'étape 2, sans les réécrire.

Outils

- Kestra
- Python
- SQL et DuckDB

Ressources

- SQL avec DuckDB : [documentation DuckDB](#)
- pandas : [documentation officielle](#)
- Python : [documentation officielle en français](#)

- Kestra, suivre une exécution et ses tâches : [composants d'un workflow](#)

4

Préparez le support et la soutenance devant le COPIL

Semaine suivante. Compétences C4, C7



Solène

À : moi

Vendredi 25 sept.

16:40

COPIL : trois minutes pour convaincre

Bravo pour cette semaine, tu t'es déjà fait une place dans l'équipe. Dernière ligne droite : tu présentes au prochain COPIL. Trois minutes de démonstration, puis les questions. Dans la salle : la direction, Capucine et Théo, qui ne sont pas techniques, et Nadir, qui l'est beaucoup.

Parle aux premiers, prépare-toi pour le second. Et tradition maison : le nouveau choisit la bouteille de la dégustation du vendredi. Ton pipeline en a repéré 30 premium, tu as l'embaras du choix.

Solène

Prérequis

- Avoir finalisé votre travail.

Résultat attendu

Un support de présentation rappelant :

- le contexte de la mission ;
- votre démarche technique complète ;
- la justification de vos choix (pourquoi Kestra, pourquoi DuckDB...).

et incluant :

- le logigramme du processus pour ingérer, nettoyer, fusionner, agréger et extraire les données ;
- la topologie du workflow Kestra ;
- une prise en main de Kestra en langage simple, adapté à l'auditoire ;

- les tests mis en place et leur rôle.

Recommandations

- Entraînez-vous à tenir la démonstration en 3 minutes.
- Anticipez les questions sur vos choix d'architecture, et sachez justifier chaque décision.
- Préparez quelques pistes d'amélioration, techniques et fonctionnelles.
- Soignez la forme : slides claires et concises, visuels, schémas, logigrammes.
- Répétez pour que le discours reste fluide, sans lire vos notes.

5

Vérifiez votre travail et faites le bilan



Complétez cette fiche d'autoévaluation, puis faites le bilan avec votre formateur·rice, tableau OpenProject à l'appui.

- ☐ J'ai rédigé une note de cadrage avant de commencer à coder.
- ☐ Mon backlog OpenProject est daté, et mon Kanban reflète mon avancement réel.
- ☐ Mon logigramme représente toutes les tâches et tous les tests.
- ☐ Kestra est installé et fonctionnel, captures d'écran prises.
- ☐ Les 4 scripts SQL DuckDB sont écrits et intégrés au .yaml.
- ☐ Le script Python de z-score est écrit et intégré au .yaml.
- ☐ Le pipeline produit le rapport CA (.xlsx) et les 2 listes de vins (.csv).
- ☐ Le trigger cron est configuré pour le 15 du mois à 9h.
- ☐ Les 5 tests demandés sont intégrés après les tâches nominales.
- ☐ Mes résultats correspondent aux valeurs de référence d'Octave.
- ☐ Mon dépôt GitHub contient tous les livrables, un README testé et des commits réguliers.

- ☐ J'ai transmis le lien de mon dépôt GitHub.
- ☐ Mon support est prêt et ma démo tient en 3 minutes.

Planning indicatif

Jour	Contenu
Lundi 21	Étape 0 : lecture de la mission, note de cadrage, backlog saisi dans OpenProject
Mardi 22	Étape 1 : logigramme complet sur Draw.io, tests représentés
Mercredi 23 et jeudi 24	Étape 2 : installation de Kestra, scripts SQL et Python, premier pipeline fonctionnel
Vendredi 25	Étape 3 : intégration des tests, vérification des valeurs de référence, envoi du lien GitHub
Semaine suivante	Étapes 4 et 5 : support, répétition de la soutenance, autoévaluation

Ce brief existe aussi en [version PDF](#).

Étude de cas fictive, Le Comptoir des Coteaux. Support de brief à remettre aux apprenant·es.